"Architecture d'Analyse Comportementale : Clustering et Classification sous PySpark"

Par :

Rubén LEONARDO

Yoan KESRAOUI

Made with GAMMA

Objectifs et Méthodologie RFM

Contenu :

- **Objectif :** Segmenter la base de données (4339 clients uniques) pour identifier les profils à forte valeur et les clients à risque de désengagement.
- **Les piliers RFM :**
  - **Récence (R) :** Temps écoulé depuis le dernier achat. Indicateur de l'engagement actuel.
  - **Fréquence (F) :** Nombre total de transactions. Mesure de la fidélité.
  - **Montant (M) :** Valeur monétaire totale générée. Indique la contribution au chiffre d'affaires.
- **Technique :** Utilisation de **PySpark** pour le traitement de données volumineuses et l'algorithme **K-Means** pour le clustering non supervisé.

Made with GAMMA

Analyse Exploratoire – La Santé de la Base

Justification du code :

- Le nettoyage des quantités négatives (retours clients) et des `CustomerID` nuls est crucial pour ne pas biaiser la moyenne de la valeur client.
- La conversion de `InvoiceDate` en format Timestamp permet de calculer une Récence précise en jours par rapport à la date de transaction la plus récente du dataset.

Interprétation Économique :

- Une distribution de récence très étalée (max > 370 jours) suggère qu'une partie importante de la base est "dormante".
- La fréquence moyenne (~4 achats) indique une base majoritairement composée d'acheteurs occasionnels, avec quelques "Power Users" (max 210 achats).

Made with GAMMA

Profilage des Segments (Le Radar du Clustering)

Justification du choix :

- Le clustering K-Means regroupe les clients ayant des comportements d'achat mathématiquement proches. Visualiser les moyennes par cluster permet de "nommer" les segments (ex: Champions, Clients à Risque).

Interprétation Économique :

- **Cluster "Champions" :** Récence faible, Fréquence et Montant très élevés. Ce sont vos ambassadeurs.
- **Cluster "Potentiels" :** Fréquence moyenne mais Montant élevé. Ils achètent peu souvent mais des produits chers.
- **Cluster "À réveiller" :** Récence très élevée. Clients qui n'ont plus interagi depuis longtemps.

Made with GAMMA

Analyse du Chiffre d'Affaires par Segment

Interprétation Économique :

- Il est fréquent d'observer la loi de Pareto (20% des clients génèrent 80% du CA).
- Identifier si le segment "Champions" pèse pour la majorité du profit permet de sécuriser le budget marketing sur la rétention plutôt que sur l'acquisition de nouveaux clients incertains.

Made with GAMMA

Stratégie Marketing Ciblée

Contenu :

1. **Pour les "Champions" :** Programme de fidélité VIP, accès en avant-première aux nouvelles collections, parrainage.
2. **Pour les "Clients Fidèles" :** Vente croisée (Cross-selling) basée sur leurs produits préférés (Top 10 identifié dans l'analyse : "WORLD WAR 2 GLIDERS", etc.).
3. **Pour les "Clients à Risque" :** Campagnes de "Win-back" avec des coupons de réduction agressifs pour tester leur réactivité.
4. **Pour les "Nouveaux Clients" :** Séquence d'onboarding pour les transformer en acheteurs fréquents.

Made with GAMMA

Conclusion et Recommandations

Recommandations Stratégiques :

- **Personnalisation :** Ne plus envoyer le même catalogue à toute la base. Allouer le budget marketing au prorata de la valeur potentielle de chaque segment.
- **Automatisation :** Utiliser les résultats du clustering pour déclencher des emails automatiques dès qu'un client change de segment (ex: un Champion qui devient "Tiède").
- **Suivi de la LTV (Lifetime Value) :** Le modèle RFM doit être mis à jour mensuellement pour observer le déplacement des clients entre les clusters.

Made with GAMMA

Du Montant au Profil (Classification)

Objectif : Prédire la probabilité qu'un client appartienne au segment "Haute Valeur".

- **Variable Cible () :** `label` (1 = Gros Dépensier, 0 = Petit Dépensier).
- **Seuil de coupure (Threshold) :** Le montant à partir duquel un client change de statut.
- **Variables Prédictives () :** Récence et Fréquence.
- **Algorithme :** Régression Logistique (PySpark).

Made with GAMMA

Justification des Choix Techniques

Le Pipeline ML :

- `Binarizer` **:** Ce choix est stratégique pour le marketing. Plutôt que de prédire un montant exact (difficile et souvent erroné), on simplifie la décision : "Faut-il investir sur ce client, oui ou non ?".
- `VectorAssembler` **:** Regroupe les caractéristiques comportementales dans un seul objet mathématique pour le modèle.
- `LogisticRegression` **:** Idéal car il ne donne pas seulement une classe, mais une **probabilité** (ex: ce client a 85% de chances d'être un gros dépensier).

Made with GAMMA

La Matrice de Confusion – Précision du Ciblage

Interprétation Économique :

- **Vrais Positifs (VP) :** Les gros dépensiers que nous avons bien identifiés. Succès du ciblage.
- **Faux Positifs (FP) :** Le "coût pour rien". On prédit un gros client, mais il dépense peu. On risque de gaspiller des ressources (échantillons gratuits, appels prioritaires).
- **Faux Négatifs (FN) :** Le "manque à gagner". Ce sont des pépites que le modèle n'a pas vues. On risque de les perdre par manque d'attention.

Made with GAMMA

Analyse des Leviers (Coefficients de Logistique)

Interprétation Économique : Le modèle de régression logistique nous donne l'impact de chaque variable sur la **probabilité** de devenir un gros dépensier.

- **Impact de la Fréquence :** Si le coefficient est élevé et positif, chaque achat supplémentaire augmente exponentiellement les chances de passer dans le segment "Gros Dépensier".
- **Impact de la Récence :** Si le coefficient est négatif, chaque jour sans achat "plombe" la probabilité de valeur future du client.

Made with GAMMA

Conclusion et Stratégie Marketing

Recommandations :

1. **Ciblage Prédictif :** Utiliser les probabilités de sortie du modèle pour créer un segment "Potentiels à convertir" (ceux qui ont une probabilité de 0.45 à 0.60 d'être gros dépensiers).
2. **Optimisation du ROI :** Ne déclencher des offres coûteuses (cadeaux, remises importantes) que pour les clients ayant une probabilité > 0.80 d'être rentables.
3. **Alerte Churn :** Un client "Gros Dépensier" dont la probabilité chute subitement selon le modèle doit être contacté immédiatement par le service client.

Made with GAMMA